

Предсказание волатильности российского фондового рынка: сравнительный анализ GARCH, LSTM и Transformer

Старченко Александр Николаевич

Студент ИТМО

Email: astroblartvks@gmail.com

Научный руководитель: Лабин Юрий Владимирович

26 апреля 2026 г.

Аннотация

В работе проведено сравнение классической эконометрической модели GARCH и нейросетевых архитектур LSTM и Transformer для задачи прогнозирования волатильности индекса Московской биржи (IMOEX). На дневных лог-доходностях за 2010–2026 гг. обучены модели, и оценена точность одношагового прогноза реализованной волатильности. Результаты показывают, что GARCH(1,1) превосходит обе нейросети по среднеквадратичной ошибке и коэффициенту детерминации R^2 , тогда как Transformer демонстрирует наихудшее качество. Обсуждаются причины неудачи Transformer на финансовых временных рядах и обозначены перспективы гибридного подхода GINN.

1 Введение

Волатильность является одним из ключевых параметров в управлении финансовыми рисками. На её основе рассчитываются резервы капитала, стоимость опционов и величина VaR (Value-at-Risk). Точное предсказание волатильности особенно важно для развивающихся рынков, к которым относится и российский фондовый рынок. Индекс Мосбиржи (IMOEX) – его основной индикатор; он подвержен резким скачкам, вызванным как глобальными шоками, так и внутренними событиями (кризисы 2014, 2020, 2022 гг.).

Классическим инструментом моделирования волатильности является семейство GARCH (Generalized Autoregressive Conditional Heteroskedasticity) [1]. Эти модели хорошо описывают кластеризацию волатильности, но могут плохо улавливать нелинейные зависимости. С развитием глубокого обучения для предсказания волатильности всё чаще применяются рекуррентные нейронные сети (LSTM, GRU) [2] и архитектуры на основе механизма внимания (Transformer) [3]. Однако результаты сравнения неоднозначны: на одних рынках нейросети превосходят GARCH, на других – уступают.

Для IMOEX уже проводилось сравнение GARCH и LSTM на данных до 2023 г. в выпускной квалификационной работе ВШЭ [5], где LSTM показал несколько лучшие результаты. Однако исследований с Transformer для российского индекса в открытом доступе не обнаружено. Более того, недавняя работа [4] предложила гибридную архитектуру GINN (GARCH-Informed Neural Network), объединяющую GARCH и LSTM через специальную функцию потерь; модель показала преимущество на семи мировых индексах, но на российском рынке не тестировалась.

Цель данной работы – провести прямое сравнение GARCH, LSTM и Transformer на данных IMOEX за максимально доступный период (2010–2026 гг.), оценить их способность предсказывать волатильность на один день вперёд и проанализировать поведение в кризисный период. Гибридная модель GINN исследуется отдельно и будет представлена в последующих публикациях.

2 Обзор литературы

Модель GARCH, предложенная Боллерселем [1], описывает условную дисперсию как линейную функцию прошлых квадратов ошибок и прошлых значений дисперсии. Для финансовых временных рядов чаще всего достаточно GARCH(1,1) [6]. Её преимущества – интерпретируемость и малое число параметров; недостаток – линейная структура, не учитывающая асимметрию и резкие смены режима.

Рекуррентные сети, особенно LSTM, активно применяются к предсказанию волатильности. Например, [2] использовали гибрид LSTM и GARCH для индекса KOSPI и показали улучшение точности. В работе [5] на данных IMOEX 2013–2023 LSTM продемонстрировал лучшее качество по сравнению с GARCH, однако разница в периодах и методологии не позволяет напрямую обобщать результаты.

Transformer, первоначально разработанный для обработки естествен-

ного языка [3], был адаптирован для временных рядов. Его механизм самовнимания потенциально способен улавливать долгосрочные зависимости. Однако финансовые ряды обладают сильной локальной инерцией и редкими, но значимыми выбросами. Ряд исследований указывают на то, что Transformer без специальной модификации часто уступает LSTM в задачах с ограниченным объёмом данных [7].

Гибридная модель GINN [4] объединяет прогноз GARCH и нейросеть через выпуклую комбинацию в функции потерь: $\mathcal{L} = \lambda \text{MSE}(\sigma_{\text{real}}^2, \hat{\sigma}_{\text{GINN}}^2) + (1-\lambda) \text{MSE}(\sigma_{\text{GARCH}}^2, \hat{\sigma}_{\text{GINN}}^2)$. При $\lambda = 0$ модель учится имитировать GARCH, что само по себе может давать более стабильный прогноз, чем обучение на реальной волатильности.

3 Данные и описательная статистика

Использовались ежедневные цены закрытия индекса IMOEX за период с 12.01.2010 по 03.04.2026 (4077 наблюдений), полученные с официального сайта Московской биржи. Дневные лог-доходности рассчитаны как

$$r_t = \ln \left(\frac{P_t}{P_{t-1}} \right) \times 100\%. \quad (1)$$

Для них характерна кластеризация волатильности, «тяжёлые хвосты» и асимметрия (рис. ??).

Реализованная волатильность (таргет) определялась как 20-дневное скользящее стандартное отклонение доходностей:

$$\sigma_t = \sqrt{\frac{1}{20} \sum_{i=0}^{19} (r_{t-i} - \bar{r}_t)^2}. \quad (2)$$

Данные разделены на три непересекающихся периода:

- **Train:** 02.02.2010 – 31.12.2019 (около 2500 дней);
- **Validation:** 01.01.2020 – 31.12.2021 (около 500 дней);
- **Test:** 01.01.2022 – 03.04.2026 (около 1062 дней).

Такое разбиение имитирует реальное применение: модель обучается на исторических данных, настраивается на «докризисном» 2020–2021 гг. и тестируется на новейшем периоде, включающем события 2022 года.




Рис. 1: Лог-доходности IMOEX (2010–2026).

4 Методология

4.1 GARCH(1,1)

Модель задаётся уравнениями

$$r_t = \mu + \varepsilon_t, \quad (3)$$

$$\varepsilon_t = \sigma_t z_t, \quad z_t \sim \mathcal{N}(0, 1), \quad (4)$$

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2, \quad (5)$$

где $\omega > 0$, $\alpha, \beta \geq 0$, $\alpha + \beta < 1$. Параметры оценивались методом максимального правдоподобия на окне длиной 90 дней. Для каждого дня тестовой выборки строился одношаговый прогноз дисперсии, из которого извлекался квадратный корень.

4.2 LSTM

Использовалась архитектура, аналогичная предложенной в [4] для семейства GINN:

- Три слоя LSTM с 256 скрытыми нейронами каждый;
- Dropout между слоями (0.2);
- BatchNorm после последнего LSTM;

- Два полносвязных слоя: $256 \rightarrow 128$ (ReLU) $\rightarrow 1$.

Входной признак – логарифм сглаженной реализованной дисперсии (методика [4]):

$$\sigma_t^2 = \frac{1}{5} \sum_{i=0}^4 (r_{t-i} - \hat{\mu}_{t-i})^2,$$

где $\hat{\mu}_t$ – 90-дневное скользящее среднее. Применялось log-преобразование $\ln(1 + \sigma_t^2)$ для борьбы с тяжёлым правым хвостом. Модель обучалась предсказывать значение на следующий день по окну из 90 предыдущих значений. Обучение – 300 эпох, оптимизатор AdamW с начальным шагом 10^{-3} и уменьшением на плато. Ранняя остановка при отсутствии улучшения на валидации в течение 30 эпох. Функция потерь – MSE.

4.3 Transformer

Реализован стандартный TransformerEncoder [3]:

- Входной слой: линейное отображение $1 \rightarrow 64$ ($d_{model} = 64$);
- Позиционное кодирование (обучаемое);
- 2 энкодерных слоя с 4 головами внимания и размером скрытого слоя 256;
- Выходной слой: $64 \rightarrow 1$ (ReLU, Dropout).

Обучение проводилось с теми же гиперпараметрами, что и LSTM, но потребовалось значительно меньше эпох до ранней остановки (78 эпох).

4.4 Метрики

Прогнозы денормализовывались (обратное log-преобразование) и сравнивались с σ_t . Использовались:

$$\text{MSE} = \frac{1}{N} \sum (\sigma_t - \hat{\sigma}_t)^2, \quad \text{MAE} = \frac{1}{N} \sum |\sigma_t - \hat{\sigma}_t|, \quad R^2 = 1 - \frac{\sum (\sigma_t - \hat{\sigma}_t)^2}{\sum (\sigma_t - \bar{\sigma})^2}.$$

5 Результаты

5.1 Сравнение точности прогнозов

Основные результаты на тестовом периоде приведены в таблице 1. На рис. ?? показаны прогнозы всех моделей вместе с реализованной волатильностью.

Таблица 1: Метрики качества прогнозов на тестовой выборке (2022–2026).

Модель	MSE	MAE	R^2
GARCH(1,1)	261.23	2.39	0.642
LSTM	350.92	1.95	0.519
Transformer	635.62	2.45	0.128

GARCH оказался лидером по MSE и R^2 , объясняя около 64% дисперсии реализованной волатильности. LSTM дал меньшую MAE, что говорит о меньшем среднем абсолютном отклонении, но хуже справился с выбросами. Transformer показал наихудшие результаты: R^2 всего 0.13 свидетельствует о том, что модель практически не улавливает динамику волатильности.

Волатильность: все модели vs реальность




Рис. 2: Прогнозы GARCH на тестовом периоде (2022–2026).




Рис. 3: Прогнозы LSTM на тестовом периоде (2022–2026).




Рис. 4: Прогнозы GARCH, LSTM и Transformer на тестовом периоде (2022–2026).

5.2 Поведение в кризисный период 2022 г.

Наиболее яркий скачок волатильности пришёлся на конец февраля – начало марта 2022 г. GARCH быстро отреагировал ростом прогнозной

волатильности, хотя и с некоторым запаздыванием (рис. 2). LSTM предсказал лишь умеренный рост, значительно недооценив масштаб шока (рис. 3). Transformer продемонстрировал почти плоскую линию, полностью проигнорировав всплеск (рис. 4). Это подтверждает известную проблему Transformer – переобучение на спокойном режиме и неспособность к быстрой адаптации при смене режима без дополнительного дообучения.




Рис. 5: Кризис 2022 года: GARCH, LSTM и Transformer.

6 Обсуждение

Уступая GARCH по MSE и R^2 , LSTM выигрывает по MAE, что может объясняться его способностью давать более гладкие прогнозы в спокойные периоды. Однако для риск-менеджмента важнее не промахнуться в хвостах, и здесь GARCH остаётся более надёжным инструментом.

Провал Transformer, на наш взгляд, обусловлен тремя причинами:

1. **Локальная структура данных.** Волатильность обладает сильной серийной зависимостью: сегодняшнее значение сильно коррелирует со вчерашним, но слабо – с тем, что было 90 дней назад. Механизм самовнимания, ищущий глобальные взаимодействия, размывает эту локальную информацию.
2. **Недостаток данных.** Transformer'у требуется больше обучающих примеров, чем способен предоставить фондовый рынок (всего ~ 2500

тренировочных окон).

3. **Переобучение на низкой волатильности.** Модель «запомнила» спокойный характер ряда, доминировавший в 2010-х, и экстраполирует его на любые будущие данные.

Полученные результаты согласуются с выводами [4] о том, что даже простой LSTM не всегда превосходит GARCH, и мотивируют развитие гибридных подходов, таких как GINN. Добавление GARCH-сигнала в функцию потерь может стабилизировать обучение нейросети и улучшить реакцию на стрессовые сценарии.

7 Заключение

В работе выполнено сравнение трёх моделей прогнозирования волатильности IMOEX. Классический GARCH(1,1) показал наилучшие результаты по точности, LSTM – сопоставимое качество с меньшей MAE, а Transformer оказался непригоден для данной задачи в его стандартной реализации.

В дальнейшем планируется:

- Реализовать и исследовать гибридную модель GINN (включая вариант GINN-0) на российских данных;
- Провести VaR-бэктестинг для оценки практической применимости моделей;
- Включить в анализ кризисы 2014 и 2020 гг. путём расширения тестового периода или кросс-валидации.

Список литературы

- [1] Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- [2] Kim, H. Y., & Won, C. H. (2018). Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models. *Expert Systems with Applications*, 103, 25–37.
- [3] Vaswani, A. et al. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.

- [4] Xu, Q. et al. (2024). A GARCH-Informed Neural Network for Volatility Forecasting. *Carnegie Mellon University / SSRN Working Paper*.
- [5] Выпускная квалификационная работа НИУ ВШЭ (2023). Прогнозирование волатильности российского фондового рынка с использованием LSTM и GARCH. URL: <https://www.hse.ru/edu/vkr/931805743>.
- [6] Hansen, P. R., & Lunde, A. (2005). A forecast comparison of volatility models: does anything beat a GARCH(1,1)? *Journal of Applied Econometrics*, 20(7), 873–889.
- [7] Zeng, A. et al. (2022). Are Transformers Effective for Time Series Forecasting? *arXiv preprint arXiv:2205.13504*.