

GARCH-Informed Neural Networks for Volatility Prediction in Financial Markets

Zeda Xu

College of Engineering
Carnegie Mellon University
Pittsburgh, PA, USA, 15213
zedaxu@cmu.edu

John Liechty

Smeal College of Business
Pennsylvania State University
University Park, PA, USA, 16802
jcl12@psu.edu

Sebastian Benthall

School of Law
New York University
New York City, NY, USA, 10012
spb413@nyu.edu

Nicholas Skar-Gislinge

Lund University
Lund, Sweden
nsgk@pm.me

Christopher McComb

College of Engineering
Carnegie Mellon University
Pittsburgh, PA, USA, 15213
ccm@cmu.edu

Abstract—Volatility, which indicates the dispersion of returns, is a crucial measure of risk and is hence used extensively for pricing and discriminating between different financial investments. As a result, accurate volatility prediction receives extensive attention. The Generalized Autoregressive Conditional Heteroscedasticity (GARCH) model and its succeeding variants are well established models for stock volatility forecasting. More recently, deep learning models have gained popularity in volatility prediction as they demonstrated promising accuracy in certain time series prediction tasks. Inspired by Physics-Informed Neural Networks (PINN), we constructed a new, hybrid Deep Learning model that combines the strengths of GARCH with the flexibility of a Long Short-Term Memory (LSTM) Deep Neural Network (DNN), thus capturing and forecasting market volatility more accurately than either class of models are capable of on their own. We refer to this novel model as a GARCH-Informed Neural Network (GINN). When compared to other time series models, GINN showed superior out-of-sample prediction performance in terms of the Coefficient of Determination (R^2), Mean Squared Error (MSE), and Mean Absolute Error (MAE).

Index Terms—neural networks, hybrid model, volatility prediction, physics informed machine learning

I. INTRODUCTION

Prediction of market trends has long been an interest of the finance community [1]. Numerous mathematical models have been proposed to fit and extrapolate historical data, with the goal of gaining exclusive insights into the future. Those models often assume that market occurrences will repeat themselves and, thus, the future is predictable based on historical data [2]. Stock price time series are noisy and volatile, and there is little to no predictability in the first moment of how a stock price changes over time [2]. There is, however, considerable structure and predictability in the second moment or volatility, which reflects the riskiness of a stock [3, 4]. Volatility prediction models aim to match and forecast the dispersion of the returns (typically on a log scale) of stock prices. These volatility predictions carry significant meaning and can inform investment decisions [3, 5].

One of the most widely used models for financial times series is the Autoregressive Conditional Heteroscedasticity (ARCH) model and many of its succeeding variations [5, 6, 7]. It captures the heteroscedasticity (non-constant variance) that is present in most real-world data, enabling the estimation of current conditional variance based on previous values [3, 6]. A generalized version of ARCH, GARCH (Generalized-ARCH) is a natural extension and widely considered as a standard model for forecasting stock volatility [8, 9, 10]. A large number of extensions of the GARCH models have subsequently been introduced, including the Exponential GARCH (EGARCH), the Glosten-Jagannathan-Runkle GARCH (GJR-GARCH) model, and the Threshold GARCH (TGARCH) model, all of which attempt to capture the leverage effect in financial time series with asymmetric volatility terms [11, 12, 13, 14, 15]. Overall, the GARCH model and its extensions have shown decent performance in financial volatility forecasting tasks, but the performance of the models isn't generalizable to all market conditions, and they are known to fail in certain market index forecasting applications [10, 16, 17, 18]. This can be attributed to the fact that models in the ARCH family are highly linear, and therefore lack the capability to capture non-linear market features [5, 17]. This characteristic hinders their prediction performance in out-of-sample time series prediction tasks.

Machine Learning (ML) models have gained considerable attention over the years for their predictive performance and self-adaptability in many complex problems. They are therefore perceived, by some, as better modeling tools than legacy statistical models [19, 20, 21]. Artificial Neural Network (ANN) models are specifically regarded as some of the most accurate and universal models in time series modeling in areas including engineering, economy, and finance [22, 23, 24]. As universal function approximators, they are a strong competitor for non-linear data modeling [3, 5, 25, 26]. In this work, we focus our attention on a special case of ANN, the Long-Short Term Memory (LSTM) model, which has shown su-

Нейронные сети с учетом модели GARCH для прогнозирования волатильности на финансовых рынках

Зеда Сью College of Engineering, Питтсбург,
Пенсильвания, США, 15213 zedaxu@cmu.edu Джон
Личти Smeal College of Business Университетский
Парк, Пенсильвания, США, 16802 jcl12@psu.edu

Себастьян Бент
холл
School of Law
New York University
Новый-Йорк Сити, Нью-Йорк,
США, 10012 spb413@nyu.edu

Николас Скэр-Гислинг Lund University
Лунд, Швеция nskg@p
m.me

Кристофер МакКом
College of Engineering
Питтсбург, Пенсильв
ания, США, 15213 ccm
@cmu.edu

Abstract—Волатильность, которая указывает на разброс с доходностей, является ключевой мерой риска и, следовательно, широко используется для оценки стоимости и различий между различными финансовыми инвестициями. В результате точное прогнозирование волатильности привлекает значительное внимание. Модель обобщённой авторегрессионной условной гетероскедастичности (GARCH) и её последующие варианты являются хорошо зарекомендовавшими себя моделями для прогнозирования волатильности акций. В последнее время модели глубокого обучения стали популярны в прогнозировании волатильности, так как они показали обнадеживающую точность в некоторых задачах прогнозирования временных рядов. Вдохновлённые физически-информированными нейронными сетями (PINN), мы создали новую, гибридную модель глубокого обучения, которая сочетает сильные стороны GARCH с гибкостью глубокой нейронной сети с долгой краткосрочной памятью (LSTM DNN), что позволяет более точно улавливать и прогнозировать рыночную волатильность, чем любой из этих классов моделей по отдельности. Мы называем эту новую модель GARCH-Informed Neural Network.

Index Terms—нейронные сети, гибридная модель, прогнозирование волатильности, машинное обучение с учётом физических закономерностей

I. ВВЕДЕНИЕ

Прогнозирование рыночных тенденций давно является интересом финансового сообщества [1]. Было предложено множество математических моделей для подгонки и экстраполяции исторических данных с целью получения эксклюзивной информации о будущем. Эти модели часто предполагают, что рыночные события будут повторяться, и, следовательно, будущее предсказуемо на основе исторических данных [2]. Временные ряды цен акций являются шумными и волатильными, и практически отсутствует предсказуемость в первом моменте изменения цены акции во времени [2]. Однако существует значительная структура и предсказуемость во втором моменте, или волатильности, которая отражает рискованность акции [3, 4]. Модели прогнозирования волатильности направлены на сопоставление и прогнозирование разброса доходностей (обычно в логарифмическом масштабе) цен акций. Эти прогнозы волатильности имеют важное значение и могут информировать инвестиционные решения [3, 5].

Одна из наиболее широко используемых моделей для финансовых временных рядов — это модель авторегрессионной условной гетероскедастичности (ARCH) и многие из её последующих вариаций [5, 6, 7]. Она учитывает гетероскедастичность (непостоянную дисперсию), присутствующую в большинстве реальных данных, что позволяет оценивать текущую условную дисперсию на основе предыдущих значений [3, 6]. Обобщённая версия ARCH, GARCH (Generalized-ARCH), является естественным расширением и широко считается стандартной моделью для прогнозирования волатильности акций [8, 9, 10]. В последующем было предложено большое количество расширений моделей GARCH, включая экспоненциальную GARCH (EGARCH), модель Глостена-Джаганнатхана-Ранкла GARCH (GJR-GARCH) и пороговую GARCH (TGARCH), все из которых стремятся учесть эффект рычага в финансовых временных рядах с асимметричными терминами волатильности [11, 12, 13, 14, 15]. В целом, модель GARCH и её расширения показали достойные результаты в прогнозировании финансовой волатильности.

Модели машинного обучения (ML) за последние годы привлекли значительное внимание благодаря своей прогнозной способности и способности к адаптации в многих сложных задачах. Поэтому их некоторые воспринимают как лучшие инструменты моделирования по сравнению с традиционными статистическими моделями [19, 20, 21]. Модели искусственных нейронных сетей (ANN) рассматриваются особенно как одни из самых точных и универсальных моделей для моделирования временных рядов в таких областях, как инженерия, экономика и финансы [22, 23, 24]. Будучи универсальными аппроксиматорами функций, они являются сильными конкурентами для моделирования нелинейных данных [3, 5, 25, 26]. В этой работе мы сосредотачиваем наше внимание на специальном случае ANN, модели долгой краткосрочной памяти (LSTM), которая показала су-

periority in prediction accuracy, universality, and adaptivity in volatility modeling and many other time series forecasting tasks [3, 27, 28, 29, 30]. However, one common problem of the ANN models, including the LSTM model, is overfitting, where the model adheres too closely to in-sample data and loses generalizability on out-of-sample predictions.

Our primary contribution draws inspiration from Physics Informed Machine Learning (PIML), an emerging class of ML that directly embeds physical laws into the architecture or loss function of a model, thereby improving generalizability and veracity [31, 32, 33]. In the same way that PIML merges ML fundamentals with physical laws, this paper merges ML with stylized facts, empirical market patterns captured by the GARCH model, which serve as the “physical laws” encoded in the model. We refer to our novel hybrid model as the GARCH-Informed Neural Network (GINN). Specifically, the GARCH model serves as a regularization mechanism incorporated in the loss function of the ANN, guarding against overfitting. Since the GINN model learns from both the factual ground truth and the knowledge acquired by the GARCH model, we expect it to grasp both general market trends and finer details. We hypothesize that the combination of a classic statistical approach with modern machine learning will result in a highly accurate and generalizable model.

Four models were selected as baseline models for performance comparison, namely the GARCH model, the GJR-GARCH model, the TGARCH model, and a simple, non-hybrid LSTM Neural Network model. All the models were trained and tested on 7 representative stock market indices from across the globe. The prediction accuracy is evaluated by the Coefficient of Determination (R^2), Mean Squared Error (MSE), and Mean Absolute Error (MAE).

II. METHODOLOGY

A. Volatility Process Modeling

This paper focuses on stock market volatility, which is represented by the variance in daily log return. We use the daily closing prices to calculate daily log returns.

Denote the daily stock close price as P_t , where t represents time. The daily stock log return is then:

$$r_t = \ln \left(\frac{P_t}{P_{t-1}} \right) \quad (1)$$

Here, r_t is the daily log return at day t , P_t is the daily close stock price at day t , and P_{t-1} is the daily close stock price at the previous day $t - 1$.

The daily log return time series r_t is modeled as a linear combination of the predictable average μ_t and an unpredictable error term ε_t . That is,

$$r_t = \mu_t + \varepsilon_t \quad (2)$$

The error term ε_t consists of a normally distributed random noise e_t and the conditional variance σ_t^2 that is based on past information of the time series. Different variants of the

GARCH-type models have different modeling of the volatility process [8, 12, 13, 34]. That is,

$$\varepsilon_t = \sigma_t e_t, e_t \stackrel{\text{iid}}{\sim} N(0, 1) \quad (3)$$

- GARCH:

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 \quad (4)$$

- GJR-GARCH:

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^o \gamma_j \varepsilon_{t-j}^2 I + \sum_{k=1}^p \beta_k \sigma_{t-k}^2 \quad (5a)$$

$$I = \begin{cases} 1, & \text{if } \varepsilon_{t-j} < 0 \\ 0, & \text{otherwise} \end{cases} \quad (5b)$$

- TGARCH:

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i |\varepsilon_{t-i}| + \sum_{j=1}^o \gamma_j |\varepsilon_{t-j}| I + \sum_{k=1}^p \beta_k \sigma_{t-k}^2 \quad (6a)$$

$$I = \begin{cases} 1, & \text{if } \varepsilon_{t-j} < 0 \\ 0, & \text{otherwise} \end{cases} \quad (6b)$$

, where α s, β s, and γ s are the coefficients, ε s are the error terms, and σ s are the variances.

For the LSTM and GINN model, we model the daily log return time series r_t as normally distributed with an average value μ_t and a standard deviation σ_t . That is,

$$r_t \stackrel{\text{iid}}{\sim} N(\mu_t, \sigma_t) \quad (7)$$

The volatility could then be predicted from past volatility values:

$$\sigma_t^2 = f(\sigma_{past}^2) \quad (8)$$

For a given stock log return time series r_t , denote the true daily volatility as σ_t^2 and the predicted daily volatility as $\hat{\sigma}_t^2$. The aim of the time series models is to forecast the variance $\hat{\sigma}_t^2$ for the day t on a rolling basis based on the past stock log return values r_t of a finite time window.

B. Comparison Model Selection

To set a baseline for contemporary time-series modeling, and a meaningful performance comparison for the new GINN model, several variants of the GARCH models were selected to be the baseline models for performance evaluation. Namely, the (1,1) GARCH model, the (1,1,1) GJR-GARCH model, and the (1,1,1) TGARCH model were selected as statistical models for comparison. They were selected for their representativeness, performance, and wide recognition in the time-series field. For simplicity, the (p, o, q) values of the ARCH-like models will be dropped from the name in the following sections of the paper. All GARCH-type modeling and related calculations are done in Python with the *arch* library by

превосходство в точности прогнозирования, универсальности и адаптивности в моделировании волатильности и во многих других задачах прогнозирования временных рядов [3, 27, 28, 29, 30]. Однако одной из общих проблем моделей ИНС, включая модель LSTM, является переобучение, когда модель слишком сильно подстраивается под данные внутри выборки и теряет обобщающие способности для прогнозов вне выборки.

Наш основной вклад черпает вдохновение из Physics Informed Machine Learning (PIML), новой области машинного обучения, которая напрямую интегрирует физические законы в архитектуру или функцию потерь модели, тем самым повышая обобщаемость и достоверность [31, 32, 33]. Подобно тому, как PIML объединяет основы машинного обучения с физическими законами, эта работа объединяет машинное обучение с стилизованными факторами — эмпирическими рыночными паттернами, зафиксированными моделью GARCH, которые служат «физическими законами», закодированными в модели. Мы называем нашу новую гибридную модель GARCH-Informed Neural Network (GINN). В частности, модель GARCH служит механизмом регуляризации, включённым в функцию потерь ANN, защищая от переобучения. Поскольку модель GINN учится как на фактической истинной информации, так и на знаниях, приобретённых моделью GARCH, мы ожидаем, что она будет понимать как общие рыночные тенденции, так и более тонкие детали. Мы предполагаем, что комбинация классического статистического подхода с современным машинным обучением приведёт к

В качестве базовых моделей для сравнения производительности были выбраны четыре модели: модель GARCH, модель GJR-GARCH, модель TGARCH и простая, не гибридная модель нейронной сети LSTM. Все модели были обучены и протестированы на 7 представительных фондовых индексах со всего мира. Точность прогнозирования оценивается с помощью коэффициента детерминации (R^2), среднеквадратической ошибки (MSE) и средней абсолютной ошибки (MAE).

II. МЕТОДОЛОГИЯ

A. Volatility Process Modeling

В данной работе основное внимание уделяется волатильности фондового рынка, которая представлена дисперсией ежедневной логарифмической доходности. Мы используем ежедневные цены закрытия для расчета ежедневной логарифмической доходности, обозначаемой как r_t , где t представляет время. Ежедневная логарифмическая доходность акции тогда будет:

$$r_t = \ln \left(\frac{P_t}{P_{t-1}} \right) \quad (1)$$

Здесь r_t — это дневная доходность по логарифму на день t , P_t — это дневная цена закрытия акции на день t , а P_{t-1} — это дневная цена закрытия акции на предыдущий день $t - 1$.

Серия временных рядов дневной логарифмической доходности r_t моделируется как линейная комбинация предсказуемого среднего значения μ_t и непредсказуемой случайной ошибки ε_t . То есть,

$$r_t = \mu_t + \varepsilon_t \quad (2)$$

Ошибка ε_t состоит из нормально распределенного случайного шума e_t и условной дисперсии σ_t^2 , основанной на прошлой информации временного ряда a . Различные варианты

Модели типа GARCH имеют различное моделирование процесса волатильности [8, 12, 13, 34]. То есть,

$$\varepsilon_t = \sigma_t e_t, e_t \stackrel{\text{iid}}{\sim} N(0, 1) \quad (3)$$

- GARCH:

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 \quad (4)$$

- GJR-GARCH:

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^o \gamma_j \varepsilon_{t-j}^2 I + \sum_{k=1}^p \beta_k \sigma_{t-k}^2 \quad (5a)$$

$$I = \begin{cases} 1, & \text{if } \varepsilon_{t-j} < 0 \\ 0, & \text{otherwise} \end{cases} \quad (5b)$$

- TGARCH:

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i |\varepsilon_{t-i}| + \sum_{j=1}^o \gamma_j |\varepsilon_{t-j}| I + \sum_{k=1}^p \beta_k \sigma_{t-k}^2 \quad (6a)$$

$$I = \begin{cases} 1, & \text{if } \varepsilon_{t-j} < 0 \\ 0, & \text{otherwise} \end{cases} \quad (6b)$$

, где α_s , β_s и γ_s — это коэффициенты, ε_s — это ошибки, а σ_s — это дисперсии.

Для модели LSTM и GINN мы моделируем временной ряд ежедневной логарифмической доходности r_t как нормально распределённый со средним значением μ_t и стандартным отклонением σ_t . То есть,

$$r_t \stackrel{\text{iid}}{\sim} N(\mu_t, \sigma_t) \quad (7)$$

Волатильность затем можно было бы предсказать на основе прошлых значений волатильности:

$$\sigma_t^2 = f(\sigma_{past}^2) \quad (8)$$

Для данного временного ряда логарифмических доходностей акций r_t обозначим истинную дневную волатильность как σ_t^2 , а прогнозируемую дневную волатильность как $\hat{\sigma}_t^2$. Целью моделей временных рядов заключается в прогнозировании дисперсии σ_t^2 на день t на скользящей основе, исходя из прошлых значений логарифмических доходностей акций r_t за конечное окно времени.

B. Comparison Model Selection

Чтобы установить базовый уровень для современного моделирования временных рядов и провести значимое сравнение производительности новой модели GINN, было выбрано несколько вариантов моделей GARCH в качестве базовых моделей для оценки производительности. А именно, модель GARCH (1,1), модель GJR-GARCH (1,1,1) и модель TGARCH (1,1,1) были выбраны в качестве статистических моделей для сравнения. Они были выбраны за их представительность, производительность и широкое признание в области временных рядов. Для удобства значения (p, o, q) моделей типа ARCH будут опущены из названия в последующих разделах статьи. Все моделирование типа GARCH и связанные с ним вычисления выполняются на Python с использованием библиотеки *arch*.

Kevin Sheppard [34]. A naïve LSTM model was selected as an additional baseline model, representing the modern ML models in the time-series forecasting domain. The LSTM model and the LSTM component of the GINN model are deployed, trained, and tested with the *PyTorch* library [35].

C. GARCH-Type Model Formulation

The GARCH-type models construct their volatility process upon an autoregressive (AR) estimation of the average daily log return $\hat{\mu}_t$, with a daily log return time series input r_t . All selected GARCH-type models were configured in the same way to make rolling predictions. More specifically, the GARCH-type models would forecast the variance $\hat{\sigma}_t^2$ for the day t on a rolling basis with the mean estimation from an AR model using the daily stock log return r_t for the past 90 days ($r_{t-90}, r_{t-89}, r_{t-88}, \dots, r_{t-1}$). Thus, we have:

$$\hat{\sigma}_{t_{GARCH \text{ Type}}}^2 = G(r_{t-90}, r_{t-89}, r_{t-88}, \dots, r_{t-1}) \quad (9)$$

where G indicates any GARCH-type model used in this work. The variance prediction workflow diagram for GARCH-type models is shown in Figure 1.



Fig. 1. The variance prediction workflow diagram for GARCH-type models

D. LSTM Model Formulation

The procedure for the LSTM model is slightly different, as it relies on the historical ground truth variance σ_t^2 for training. The predicted daily log returns $\hat{\mu}_t$ from another model are needed to obtain the ground truth variance. This is also true for the GINN model. Here, we use the same AR model as the GARCH model to obtain predictions of the average daily log returns $\hat{\mu}_t$. The AR model forecasts the average predicted daily log returns $\hat{\mu}_t$ for the day t on a rolling basis using the daily stock log returns r_t for the past 90 days ($r_{t-90}, r_{t-89}, r_{t-88}, \dots, r_{t-1}$).

$$\hat{\mu}_t = AR(r_{t-90}, r_{t-89}, r_{t-88}, \dots, r_{t-1}) \quad (10)$$

The ground truth variance is then:

$$\sigma_t^2 = (r_t - \hat{\mu}_t)^2 \quad (11)$$

The LSTM model then predicts the variance $\hat{\sigma}_{t_{LSTM}}^2$ for the day t on a rolling basis, using σ_t^2 for the past 90 days ($\sigma_{t-90}^2, \sigma_{t-89}^2, \sigma_{t-88}^2, \dots, \sigma_{t-1}^2$). We then have:

$$\hat{\sigma}_{t_{LSTM}}^2 = LSTM(\sigma_{t-90}^2, \sigma_{t-89}^2, \sigma_{t-88}^2, \dots, \sigma_{t-1}^2) \quad (12)$$

The variance prediction workflow chart is shown in Figure 2.

The LSTM model structure is shown below. The model architecture is optimized for prediction performance and represents a modern LSTM time series model with network components commonly used in similar models. The model is sufficiently large and deep, as models with more layers and




Fig. 2. The variance prediction workflow diagram for the LSTM model

parameters obtained no meaningful performance gain in our testing. The Neural Network has 3 LSTM layers with 256 layer width and Dropout layers in between, followed by two linear layers, 1 BatchNorm layer, and 1 ReLU layer as the activation function [36, 37, 38]. The model converges with the AdamW optimizer to minimize the Mean Squared Error (MSE) on predicted variance compared to the ground truth [39].




Fig. 3. The model structure of the LSTM model

E. GINN Model Formulation

The proposed GINN model is a combination of a GARCH model and an LSTM model. It divides the time series forecasting task into two phases: initial prediction and calibration. The initial prediction phase uses a GARCH model, and the calibration phase is achieved with an LSTM model. Similar to the LSTM model introduced in Section II-D, the GINN model also needs the ground truth variance σ_t^2 for training. In the initial prediction phase, an AR model and a constant mean (1, 1) GARCH model first yield the predicted average daily log return $\hat{\mu}_t$ and variance $\hat{\sigma}_t^2$ for the day t in a rolling basis using the daily stock log returns r_t for the past 90 days ($r_{t-90}, r_{t-89}, r_{t-88}, \dots, r_{t-1}$).

$$\hat{\mu}_t = AR(r_{t-90}, r_{t-89}, r_{t-88}, \dots, r_{t-1}) \quad (13)$$

$$\hat{\sigma}_{t_{GARCH}}^2 = GARCH(r_{t-90}, r_{t-89}, r_{t-88}, \dots, r_{t-1}) \quad (14)$$

The ground truth variance is then:

$$\sigma_t^2 = (r_t - \hat{\mu}_t)^2 \quad (15)$$

In the second phase, the LSTM component of the GINN model obtains the variance prediction $\hat{\sigma}_{t_{GINN}}^2$ for the day t in a rolling basis, using ground truth variance σ_t^2 for the past 90 days ($\sigma_{t-90}^2, \sigma_{t-89}^2, \sigma_{t-88}^2, \dots, \sigma_{t-1}^2$). The variance prediction results

Кевин Шеппард [34]. Наивная модель LSTM была выбрана в качестве дополнительной базовой модели, представляя современные ML-модели в области прогнозирования временных рядов. Модель LSTM и компонент LSTM модели GINN развернуты, обучены и протестированы с использованием библиотеки PyTorch [35].

C. GARCH-Type Model Formulation

Модели типа GARCH строят свой процесс волатильности на основе авторегрессионной (AR) оценки и среднего дневного логарифмического дохода $\hat{\mu}_t$, с вводом временного ряда дневного логарифмического дохода r_t . Все выбранные модели типа GARCH были сконфигурированы одинаково для выполнения скользящих прогнозов. Более конкретно, модели типа GARCH предсказывают дисперсию $\hat{\sigma}_t^2$ на день t на скользящей основе с использованием средней оценки из AR-модели, основанной на дневных логарифмических доходах акции r_t за последние 90 дней ($r_{t-90}, r_{t-89}, r_{t-88}, \dots, r_{t-1}$). Таким образом, мы имеем:

$$\hat{\sigma}_{t, \text{GARCH Type}}^2 = G(r_{t-90}, r_{t-89}, r_{t-88}, \dots, r_{t-1}) \quad (9)$$

где G обозначает любую модель типа GARCH, использованную в этой работе. Диаграмма рабочего процесса прогнозирования дисперсии для моделей типа GARCH показана на Рисунке 1.



Рис. 1. Диаграмма рабочей последовательности прогнозирования дисперсии для моделей типа GARCH

D. LSTM Model Formulation

Процедура для модели LSTM немного отличается, так как она опирается на историческую истинную дисперсию σ_t^2 для обучения. Для получения истинной дисперсии необходимы прогнозируемые дневные лог-доходности $\hat{\mu}_t$ из другой модели. То же самое верно и для модели GINN. Здесь мы используем ту же модель AR, что и модель GARCH, чтобы получить прогнозы средних дневных лог-доходностей $\hat{\mu}_t$. Модель AR прогнозирует средние прогнозируемые дневные лог-доходности $\hat{\mu}_t$ на день t на скользящей основе, используя дневные лог-доходности и акций r_t за последние 90 дней ($r_{t-90}, r_{t-89}, r_{t-88}, \dots, r_{t-1}$).

$$\hat{\mu}_t = AR(r_{t-90}, r_{t-89}, r_{t-88}, \dots, r_{t-1}) \quad (10)$$

Истинная дисперсия данных тогда равна:

$$\sigma_t^2 = (r_t - \hat{\mu}_t)^2 \quad (11)$$

Модель LSTM затем прогнозирует дисперсию $\hat{\sigma}_t^2$ на день t на скользящей основе, используя $\hat{\mu}_t$ за последние 90 дней ($\sigma_{t-90}^2, \sigma_{t-89}^2, \sigma_{t-88}^2, \dots, \sigma_{t-1}^2$). Далее мы имеем:

$$\hat{\sigma}_{t, \text{LSTM}}^2 = LSTM(\sigma_{t-90}^2, \sigma_{t-89}^2, \sigma_{t-88}^2, \dots, \sigma_{t-1}^2) \quad (12)$$

Диаграмма рабочего процесса прогнозирования дисперсии показана на рисунке 2.)²

Структура модели LSTM показана ниже. Архитектура модели оптимизирована для прогнозной производительности и представляет собой современную модель временных рядов LSTM с сетевыми компонентами, часто используемыми в аналогичных моделях. Модель достаточно крупная и глубокая, так как модели с большим количеством слоев и




Рис. 2. Диаграмма рабочей последовательности прогнозирования дисперсии

полученные параметры не дали значимого прироста производительности в нашем тестировании. Нейронная сеть имеет 3 LSTM-слоя с шириной слоя 256 и слоями Dropout между ними, за которыми следуют два линейных слоя, 1 слой BatchNorm и 1 слой ReLU в качестве функции активации [36, 37, 38]. Модель сходится с оптимизатором AdamW для минимизации среднеквадратичной ошибки (MSE) между предсказанной дисперсией и эталонным значением [39].




Рис. 3. Структура модели LSTM

E. GINN Model Formulation

Предлагаемая модель GINN представляет собой комбинацию модели GARCH и модели LSTM. Она делит задачу прогнозирования временных рядов на два этапа: начальное прогнозирование и калибровка. Фаза начального прогнозирования использует модель GARCH, а этап калибровки достигается с помощью модели LSTM. Подобно модели LSTM, представленной в Разделе II-D, модель GINN также не нуждается в истинной дисперсии σ_t^2 для обучения. На этапе начального прогнозирования модель AR и модель GARCH с постоянным средним (1, 1) сначала дают предсказанное среднее дневное логарифмическое возвращение $\hat{\mu}_t$ и дисперсию $\hat{\sigma}_t^2$ для дня t на основе скользящего анализа с использованием дневных логарифмических доходностей акций r_t за последние 90 дней ($r_{t-90}, r_{t-89}, r_{t-88}, \dots, r_{t-1}$).

$$\hat{\mu}_t = AR(r_{t-90}, r_{t-89}, r_{t-88}, \dots, r_{t-1}) \quad (13)$$

$$\hat{\sigma}_{t, \text{GARCH}}^2 = GARCH(r_{t-90}, r_{t-89}, r_{t-88}, \dots, r_{t-1}) \quad (14)$$

Истинная дисперсия данных тогда равна:

$$\sigma_t^2 = (r_t - \hat{\mu}_t)^2 \quad (15)$$

На втором этапе компонент LSTM модели GINN получает прогноз дисперсии $\hat{\sigma}_{t, \text{LSTM}}^2$ на день t на скользящей основе, используя истинную дисперсию σ_t^2 за последние 90 дней ($\sigma_{t-90}^2, \sigma_{t-89}^2, \sigma_{t-88}^2, \dots, \sigma_{t-1}^2$). Результаты прогноза дисперсии

from GARCH $\hat{\sigma}_{tGARCH}^2$ would serve as a regularization term for the NN.

$$\hat{\sigma}_{tGINN}^2 = GINN(\sigma_{t-90}^2, \sigma_{t-89}^2, \sigma_{t-88}^2, \dots, \sigma_{t-1}^2) \quad (16)$$

The Neural Network model structure is identical to the LSTM model, as shown in Figure 3. It contains 3 LSTM layers with 256 layer width and in-between Dropout layers, followed by two linear layers, 1 BatchNorm layer, 1 ReLU layer, and uses the AdamW optimizer [36, 37, 38, 39].

The main difference from the naïve LSTM model is that in the GINN model, the ground truth variance σ_t^2 and the GARCH predicted variance $\hat{\sigma}_{tGARCH}^2$ both act as the ground truth labels for model training. The total loss is a weighted combination of the MSE loss between σ_t^2 and $\hat{\sigma}_{tGINN}^2$, and the MSE loss between $\hat{\sigma}_{tGARCH}^2$ and $\hat{\sigma}_{tGINN}^2$. Denote the weight as λ , we have:

$$\begin{aligned} Loss &= \lambda \times MSE(\sigma_t^2, \hat{\sigma}_{tGINN}^2) \\ &+ (1 - \lambda) \times MSE(\hat{\sigma}_{tGARCH}^2, \hat{\sigma}_{tGINN}^2) \end{aligned} \quad (17)$$

This combined loss function allows the GINN model to correct its prediction results towards a combination of the ground truth variance and the GARCH predicted results. The weight term is optimized and selected through a parametric study covered in the following subsections. The model workflow diagram is shown in Figure 4.




Fig. 4. The variance prediction workflow diagram for the GINN model

F. GINN-0 Model Formulation

Through testing, we were surprised to find that a special case of the GINN model achieved high performance. We refer to this as the GINN-0 model, indicating the GINN model with $\lambda = 0$. This means that GINN-0 only takes the volatility prediction from the GARCH model for loss calculation. That is,

$$Loss = MSE(\hat{\sigma}_{tGARCH}^2, \hat{\sigma}_{tGINN}^2) \quad (18)$$

Essentially, the GINN-0 model is trained to predict volatility results from the GARCH model.

G. Experiment Approach

For training and evaluation, 7 representative stock market indices were selected from different markets across the globe: S&P 500 Index (GSPC), Dow Jones Industrial Average (DJIA), NYSE Composite Index (NYA), Russell 2000 Index

(RUT), Hang Seng Index (HSI), Nikkei 225 (NIK) and Financial Times Stock Exchange 100 Index (FTSE).

For each aforementioned stock market index, approximately 7,500 days of daily closing values were captured from 06/01/1992 to 05/31/2022 through Yahoo Finance [40]. The exact number of days and the dates differ slightly from index to index, as the market opening and data availability vary across regions and indices. Each data source was then divided into a training set ($\sim 70\%$) and a testing set ($\sim 30\%$), with the date 06/01/2013 as the dividing point separating the two datasets to avoid information leakage.

The time series models are trained on the training data and evaluated on the separate testing data, where the training data and the testing data come from the same stock market index time series. A total of 6 different models were trained and tested. Namely, the GARCH model, the GJR-GARCH model, the TGARCH model, the LSTM model, the GINN model, and the GINN-0 model were studied. All the model predictions are made on a rolling basis with a 90-day window. Each NN model was trained multiple times to reduce the uncertainty introduced by the randomness in the machine learning weight initialization process.

To gain more insight into the relative performance of the GINN and GARCH models, we further tested them on an artificially-generated time series that explicitly satisfy the GARCH process. The GARCH model should yield equal or better performance in this simulated dataset. The volatility process of the (1, 1) GARCH model is defined as $\sigma_t^2 = \alpha_0 + \alpha\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$. Different weight values of α and β would result in a different GARCH time series, and could affect model performance.

The performance of the models is evaluated by comparing the forecasted values of variance $\hat{\sigma}_t^2$ to the ground truth variance σ_t^2 . Three different performance metrics are used for evaluation, including the Coefficient of Determination (R^2), Mean Squared Error (MSE), and Mean Absolute Error (MAE).

- 1) *Coefficient of Determination (R^2)*. The Coefficient of Determination (R^2) compares the total prediction error of the model to an average value prediction, ranging from $-\infty$ to 1. Higher values indicate more accurate predictions. A score of 1 indicates perfect predictive accuracy, 0 indicates performance identical performance to a naïve mean prediction model.
- 2) *Mean Squared Error (MSE)*. The Mean Squared Error (MSE) is the average value of the squared prediction errors between the estimated values and the observed actual values. It measures how well the model could fit the data, with a smaller value indicating more accurate prediction results and better model performance.
- 3) *Mean Absolute Error (MAE)*. Similar to the Mean Squared Error, the Mean Absolute Error (MAE) is the average value of the absolute prediction errors between the estimated values and the observed actual values. It measures how well the model fits the data, with a smaller value indicating more accurate predictions and

из GARCH $\hat{\sigma}_{tGARCH}^2$ будет служить в качестве регуляризующего члена для НС.

$$\hat{\sigma}_{tGINN}^2 = GINN(\sigma_{t-90}^2, \sigma_{t-89}^2, \sigma_{t-88}^2, \dots, \sigma_{t-1}^2) \quad (16)$$

Структура модели нейронной сети идентична модели LSTM, как показано на Рисунке 3. Она содержит 3 слоя LSTM с шириной слоя 256 и промежуточными слоями Dropout, за которыми следуют два линейных слоя, 1 слой BatchNorm, 1 слой ReLU и используется оптимизатор AdamW [36, 37, 38, 39].

Главное отличие от наивной модели LSTM заключается в том, что в модели GINN истинная дисперсия σ_t^2 и предсказанная GARCH дисперсия $\hat{\sigma}_{tGARCH}^2$ обе выступают в качестве истинных меток для обучения модели. Общая функция потерь является взвешенной комбинацией MSE-потерь между σ_t^2 и $\hat{\sigma}_{tGINN}^2$, а также MSE-потерю между σ_{tGARCH}^2 и $\hat{\sigma}_{tGINN}^2$. Обозначим вес как λ , получаем:

$$Loss = \lambda \times MSE(\sigma_t^2, \hat{\sigma}_{tGINN}^2) + (1 - \lambda) \times MSE(\hat{\sigma}_{tGARCH}^2, \hat{\sigma}_{tGINN}^2) \quad (17)$$

Эта комбинированная функция потерь позволяет модели GINN корректировать свои предсказания в направлении комбинации истинной дисперсии и предсказанных результатов GARCH. Весовой коэффициент оптимизируется и выбирается через параметрическое исследование, описанное в последующих подразделах. Диаграмма рабочего процесса модели показана на Рисунке 4.




Рис. 4. Диаграмма рабочего процесса предсказания дисперсии для модели GINN

F. GINN-0 Model Formulation

В ходе тестирования мы были удивлены, обнаружив, что особый случай модели GINN достиг высокой производительности. Мы называем это моделью GINN-0, что указывает на модель GINN с $\lambda = 0$. Это означает, что GINN-0 использует только прогноз волатильности от модели GARCH для расчета потерь. То есть,

$$Loss = MSE(\hat{\sigma}_{tGARCH}^2, \hat{\sigma}_{tGINN}^2) \quad (18)$$

По сути, модель GINN-0 обучена прогнозировать результаты волатильности, полученные с помощью модели GARCH.

G. Experiment Approach

Для обучения и оценки были выбраны 7 репрезентативных фондовых индексов с различных рынков по всему миру: индекс S&P 500 (GSPC), промышленный индекс Доу-Джонса (DJIA), составной индекс NYSE (NYA), индекс Russell 2000

(RUT), индекс Hang Seng (HSI), индекс Nikkei 225 (NIK) и индекс Financial Times Stock Exchange 100 (FTSE).

Для каждого вышеупомянутого фондового индекса было зафиксировано примерно 7 500 дней значений ежедневного закрытия с 01.06.1992 по 31.05.2022 через Yahoo Finance [40]. Точное количество дней и даты немного различаются в зависимости от индекса, поскольку время открытия рынка и доступность данных варьируются в разных регионах и по разным индексам. Каждый источник данных был затем разделен на обучающий набор (70%) и тестовый набор (30%), при этом датой разделения двух наборов данных была выбрана 01.06.2013, чтобы избежать утечки информации.

Модели временных рядов обучаются на тренировочных данных и оцениваются на отдельных тестовых данных, при этом тренировочные и тестовые данные берутся из одного и того же временного ряда индекса фондового рынка. Всего было обучено и протестировано 6 различных моделей. А именно, были изучены модель GARCH, модель GJR-GARCH, модель TGARCH, модель LSTM, модель GINN и модель GINN-0. Все прогнозы моделей выполняются на скользящей основе с окном в 90 дней. Каждая нейронная сеть обучалась несколько раз, чтобы уменьшить неопределенность, вызванную случайностью при инициализации весов в процессе машинного обучения.

Чтобы получить больше информации о сравнительной производительности моделей GINN и GARCH, мы дополнительно протестировали их на искусственно сгенерированном временном ряде, который явно удовлетворяет процессу GARCH. Модель GARCH должна показать равную или лучшую производительность на этом смоделированном наборе данных. Процесс волатильности модели GARCH (1, 1) определяется как $\sigma_t^2 = \alpha_0 + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$. Различные значения весов α и β приведут к разным временным рядам GARCH и могут повлиять на производительность модели.

Эффективность моделей оценивается путем сравнения прогнозируемых значений дисперсии $\hat{\sigma}_t^2$ с истинными значениями дисперсии σ_t^2 . Для оценки используются три различных метрики эффективности, включая коэффициент детерминации (R^2), среднеквадратичную ошибку (MSE) и среднюю абсолютную ошибку (MAE).

1) *Coefficient of Determination (R^2)*. Коэффициент детерминации (R^2) сравнивает общую ошибку прогноза модели с прогнозом на основе среднего значения, варьируясь от $-\infty$ до 1. Более высокие значения указывают на более точные прогнозы. Оценка 1 означает идеальную точность прогноза, 0 указывает на производительность, идентичную наивной модели прогнозирования по среднему значению.

2) *Mean Squared Error (MSE)*. Среднеквадратичная ошибка (MSE) — это среднее значение квадрата ошибок прогнозов между оценочными значениями и наблюдаемыми фактическими значениями. Она измеряет, насколько хорошо модель может соответствовать данным, при этом меньшее значение указывает на более точные результаты прогнозирования и лучшую производительность модели.

3) *Mean Absolute Error (MAE)*. Аналогично среднеквадратичной ошибке, средняя абсолютная ошибка (MAE) — это среднее значение абсолютных ошибок прогнозов между оценочными значениями и наблюдаемыми фактическими значениями. Она измеряет, насколько хорошо модель соответствует данным, при этом меньшие значения указывают на более точные прогнозы и

better model performance. The MAE is less sensitive to extreme values than the MSE.

Together, the Coefficient of Determination (R^2), Mean Squared Error (MSE), and Mean Absolute Error (MAE) give a comprehensive measurement of the model prediction results accuracy.

H. Parametric Study on the GINN model

The performance of the GINN model is sensitive to the choice of the weight term λ . Thus, a parametric study was conducted on the weight term in order to identify the value that maximizes predictive accuracy. Different values of λ were tested ranging from 0 to 1, with 0.01 increments between 0 and 0.2, and 0.05 increments between 0.2 and 1.

As cross validation methods like K-folds and leave-one-out are hard to achieve with continuous time series prediction while strictly preventing information leakage, a separate and dedicated dataset was used to conduct the parametric study. This provides a safeguard against overfitting on the hyper-parameter level, and also ensures the performance obtained with the optimized weight values are generalizable to other datasets. The NASDAQ Composite (IXIC) dated from 06/01/1992 to 05/31/2022 is used as the dataset for the parametric study. The dataset is also divided into a training set ($\sim 70\%$) and a testing set ($\sim 30\%$), and fed into the prediction models in 90-day windows. The results of the out-of-sample testing set are used for performance evaluation. All three criteria, Coefficient of Determination (R^2), Mean Squared Error (MSE), and Mean Absolute Error (MAE), are taken into consideration. The best weight values should maximize the Coefficient of Determination, while minimizing Mean Squared Error and Mean Absolute Error.

For each weight value, the NN model was trained multiple times to reduce the uncertainty introduced by the randomness in the machine learning weight initialization process. Both the average performance metrics results and the best performance metrics results are taken into consideration. In the case of conflicting results, the weight that yields the better average results is prioritized. Also, we look for the weight values that maximize the Coefficient of Determination (R^2) in the testing set when the results from the three performance metrics are inconclusive, as the Coefficient of Determination (R^2) is regarded as the most incisive criteria out of the three. Through testing, we determined that $\lambda = 0.01$ would yield the best performance.

It was found that both the LSTM and the GINN models reached convergence after training for 300 epochs. Since the data structure and information density is similar among the seven studied datasets, both the LSTM and the GINN models are trained for 300 epochs in all prediction tasks to ensure model convergence.

III. RESULTS

The performance results for all models in the out-of-sample testing dataset are provided in Table I. For each time series data and performance metric combination, the three best

TABLE I
PERFORMANCE RESULTS OF MODELS IN THE OUT-OF-SAMPLE TESTING DATASET

Data	Perform. Metric	GARCH	GJR-GARCH	TGARCH	LSTM	GINN	GINN-0
GSPC	R2	0.299	-0.053	-0.092	0.011	0.329	0.319
	MSE	16.471	24.473	25.263	23.241	15.774	16.004
	MAE	1.094	1.159	1.162	1.181	1.042	1.041
DJIA	R2	0.266	-0.061	0.017	0.011	0.339	0.295
	MSE	22.049	31.477	29.112	29.726	19.847	21.173
	MAE	1.122	1.192	1.169	1.185	1.068	1.053
NYA	R2	0.266	-0.159	-0.131	0.031	0.323	0.321
	MSE	19.654	30.593	29.783	25.950	18.114	18.170
	MAE	1.098	1.192	1.168	1.139	1.045	1.051
RUT	R2	0.267	-0.094	-0.005	-0.016	0.323	0.313
	MSE	13.221	19.486	17.817	18.318	12.214	12.388
	MAE	1.068	1.129	1.105	1.145	0.976	0.974
HSI	R2	0.035	-0.003	0.079	-0.154	0.052	0.058
	MSE	5.823	6.096	5.601	6.969	5.721	5.685
	MAE	1.116	1.136	1.124	1.217	1.154	1.145
NIK	R2	0.004	0.073	0.100	-0.158	0.059	0.066
	MSE	6.153	5.763	5.595	7.154	5.812	5.770
	MAE	1.110	1.086	1.075	1.127	1.036	1.047
FTSE	R2	-0.004	-0.034	0.072	-0.036	0.154	0.144
	MSE	16.391	16.851	15.100	16.918	13.819	13.979
	MAE	1.177	1.197	1.155	1.263	1.081	1.088
Color Coding Scheme							
Best Performance		Second Best		Third Best		Worst Performance	

performing models are highlighted with green and a darker shade stands for better performance. The worst performing model is highlighted in yellow.

Overall, the proposed GINN model and the GINN-0 model achieved high performance in out-of-sample prediction accuracy, beating other models in most test categories. Combined, they scored 16 first places, 18 second places, and 4 third places out of a total of 21 time series data and performance metric combinations. When looking at the scores, the GINN model is 5.81%, 22.72%, 18.79%, and 22.05% better than the GARCH model, the GJR-GARCH model, the TGARCH model, and the LSTM model, respectively, on average. The GINN-0 model is 5.43%, 22.38%, 18.45%, and 21.70% better than the GARCH model, the GJR-GARCH model, the TGARCH model, and the LSTM model, respectively, on average. The GARCH model is the third best model in most of the out-of-sample tests, proving that it is still one of the best time series volatility prediction models with a significant lead in performance compared to the GJR-GARCH model, the TGARCH model, and the LSTM model.

The performance scores from the GINN model and the GINN-0 model are quite close. The GINN model is only marginally better than the GINN-0 model in most of the tests, with a few incidences that the GINN-0 model surpasses the GINN model. Overall, the performance of these two models is highly comparable, and both models yield better prediction accuracy than other models, including the GARCH model.

Further, we provide examples of the out-of-sample prediction results on the S&P 500 Index (GSPC) data from

лучшее качество модели. MAE менее чувствителен к экстремальным значениям, чем MSE.

Совместно коэффициент детерминации (R^2), среднеквадратичная ошибка (MSE) и средняя абсолютная ошибка (MAE) дают комплексную оценку точности результатов предсказаний модели.

H. Parametric Study on the GINN model

Производительность модели GINN чувствительна к выбору весового коэффициента λ . Поэтому было проведено параметрическое исследование этого весового коэффициента с целью определения значения, которое максимизирует точность прогнозирования. Были протестированы различные значения λ в диапазоне от 0 до 1, с шагом 0,01 между 0 и 0,2 и шагом 0,05 между 0,2 и 1.

Поскольку методы кросс-валидации, такие как K-кратная и leave-one-out, трудно применимы для предсказания непрерывных временных рядов при строгом предотвращении утечки информации, для параметрического исследования использовался отдельный и специализированный набор данных. Это обеспечивает защиту от переобучения на уровне гиперпараметров и также гарантирует, что показатели, полученные с оптимизированными значениями весов, могут быть обобщены на другие наборы данных. В качестве набора данных для параметрического исследования используется индекс NASDAQ Composite (IXIC) за период с 01.06.1992 по 31.05.2022. Набор данных также разделен на обучающую выборку (~70%) и тестовую выборку (~30%) и подается в модели прогнозирования окнами по 90 дней. Результаты тестирования на выборке извне используются для оценки производительности. Все три критерия — коэффициент детерминации (R^2), среднеквадратичная ошибка (MSE) и средняя абсолютная ошибка (MAE) — учитываются. Лучшие значения весов должны максимизировать коэффициент детерминации, одновременно минимизируя

Для каждого значения веса модель HC обучалась несколько раз, чтобы уменьшить неопределенность, вызванную случайностью в процессе инициализации весов в машинном обучении. Учитываются как средние показатели эффективности, так и лучшие показатели эффективности. В случае противоречивых результатов приоритет отдается весу, который дает лучшие средние результаты. Также мы ищем значения весов, которые максимизируют коэффициент детерминации (R^2) на тестовом наборе, когда результаты по трем показателям эффективности являются неубедительными, так как коэффициент детерминации (R^2) считается самым точным критерием из трех. В ходе тестирования мы определили, что $\lambda = 0.01$ даст наилучшую производительность.

Было обнаружено, что как модели LSTM, так и модели GINN достигают сходимости после обучения в течение 300 эпох. Поскольку структура данных и плотность информации схожи среди семи изученных наборов данных, обе модели, LSTM и GINN, обучаются в течение 300 эпох во всех задачах прогнозирования, чтобы обеспечить сходимость модели.

III. РЕЗУЛЬТАТЫ

Результаты производительности всех моделей на вневывборочной тестовой выборке приведены в Таблице I. Для каждой комбинации временного ряда и показателя производительности выделены три лучших

ТАБЛИЦА I РЕЗУЛЬТАТЫ РАБОТЫ МОДЕЛЕЙ НА ДАННЫХ ТЕСТИРОВАНИЯ ВНЕ ВЫБОРКИ

Data	Perform. Metric	GARCH	GJR-GARCH	TGARCH	LSTM	GINN	GINN-0
GSPC	R2	0.299	-0.053	-0.092	0.011	0.329	0.319
	MSE	16.471	24.473	25.263	23.241	15.774	16.004
	MAE	1.094	1.159	1.162	1.181	1.042	1.041
DJIA	R2	0.266	-0.061	0.017	0.011	0.339	0.295
	MSE	22.049	31.477	29.112	29.726	19.847	21.173
	MAE	1.122	1.192	1.169	1.185	1.068	1.053
NYA	R2	0.266	-0.159	-0.131	0.031	0.323	0.321
	MSE	19.654	30.593	29.783	25.950	18.114	18.170
	MAE	1.098	1.192	1.168	1.139	1.045	1.051
RUT	R2	0.267	-0.094	-0.005	-0.016	0.323	0.313
	MSE	13.221	19.486	17.817	18.318	12.214	12.388
	MAE	1.068	1.129	1.105	1.145	0.976	0.974
HSI	R2	0.035	-0.003	0.079	-0.154	0.052	0.058
	MSE	5.823	6.096	5.601	6.969	5.721	5.685
	MAE	1.116	1.136	1.124	1.217	1.154	1.145
NIK	R2	0.004	0.073	0.100	-0.158	0.059	0.066
	MSE	6.153	5.763	5.595	7.154	5.812	5.770
	MAE	1.110	1.086	1.075	1.127	1.036	1.047
FTSE	R2	-0.004	-0.034	0.072	-0.036	0.154	0.144
	MSE	16.391	16.851	15.100	16.918	13.819	13.979
	MAE	1.177	1.197	1.155	1.263	1.081	1.088
Color Coding Scheme							
Best Performance		Second Best		Third Best		Worst Performance	

Лучшие модели выделены зеленым цветом, а более темный оттенок обозначает лучшую производительность. Худшая модель выделена желтым цветом.

В целом, предложенные модели GINN и GINN-0 достигли высоких результатов в точности прогноза на новых данных, превзойдя другие модели в большинстве тестовых категорий. В сумме они заняли 16 первых мест, 18 вторых мест и 4 третьих места из общего числа 21 комбинации временных рядов и метрик производительности. При рассмотрении оценок, модель GINN в среднем превзошла модель GARCH, GJR-GARCH, TGARCH и LSTM на 5.81%, 22.72%, 18.79% и 22.05% соответственно. Модель GINN-0 в среднем превзошла модели GARCH, GJR-GARCH, TGARCH и LSTM на 5.43%, 22.38%, 18.45% и 21.70% соответственно. Модель GARCH является третьей по эффективности в большинстве тестов на новых данных, что доказывает, что она по-прежнему является одной из лучших моделей прогнозирования волатильности временных рядов с значительным преимуществом в результатах по сравнению с моделями GJR-GARCH, TGARCH и LSTM.

Показатели производительности моделей GINN и GINN-0 довольно близки. Модель GINN лишь немного лучше модели GINN-0 в большинстве тестов, хотя есть несколько случаев, когда модель GINN-0 превосходит модель GINN. В целом, производительность этих двух моделей весьма сопоставима, и обе модели обеспечивают лучшую точность прогнозирования по сравнению с другими моделями, включая модель GARCH.

Кроме того, мы приводим примеры результатов предсказаний вне выборки на данных индекса S&P 500 (GSPC) с

the six models against the ground truth values in Figure 5. The variance values are presented in a logarithmic scale. The horizontal axis is the date, and the vertical axis is the variance value.




Fig. 5. Daily volatility prediction results from all tested models on the out-of-sample testing set on the S&P 500 Index (GSPC) data

In general, the visualized results align with the numerical scores of model performance. The out-of-sample prediction results from the LSTM appear fairly random, barely capturing the larger market moves. The GJR-GARCH model and the TGARCH model successfully captured the peaks in the market (e.g., the spike in volatility in mid-2020), with seemingly more accurate magnitude prediction than the rest. However, the highly fluctuating results in the low-volatility area appear less accurate compared to the GARCH model. The GARCH results are overall smoother while preserving the market trends. The results from the GINN model and the GINN-0 fluctuate even less in comparison, to the point where it seemingly loses track of the finer details (discussed further in Section IV).

For easier comparison among the three best-performing models, the prediction results on the S&P 500 Index (GSPC) data of the GARCH model, the GINN model, and the GINN-0 model are plotted in a logarithmic scale in Figure 6. The horizontal axis is the date, and the vertical axis is the variance value.

From the plot, the results from the three models look similar in shape, but with different magnitudes. The results from the GINN model look like a much smoother version of that from the GARCH model. The peak values are far less extreme, and the curve is smoother overall in day-to-day changes. The results from the GINN-0 model are highly similar to those from the GINN model. The curves from the GINN model and the GINN-0 model are hardly distinguishable, which matches the closeness in performance metrics scoring between the two. The GARCH model captures the market changes better than the GINN and GINN-0 models, as its curve matches the ground truth better with a more accurate depiction of the peak volatility locations and magnitudes especially in the highly volatile periods.




Fig. 6. Daily volatility prediction results from the GARCH model, the GINN model, and the GINN-0 model on the out-of-sample testing set on the S&P 500 Index (GSPC) data

Compared to the ground truth values, all three models did poorly. This matches the generally poor scores of Coefficient of Determination (R^2) with all tested models, with the GINN model being the best performer at around 0.33 on the GSPC dataset.

As for the model performance on the simulated GARCH process data, we found that the relative performance of the GINN and GARCH models are highly related to the persistence of the time series data, and the GARCH model yields better accuracy in only about half of the simulated time series data tested. The persistence of a (1, 1) GARCH model is the property of momentum in conditional variance, and is defined as the sum of the weights $\pi = \alpha + \beta$ [41]. It is found that when persistence is high ($0.9 \leq \pi < 1$), the GARCH model seems to perform comparably with or outperform the GINN model, while the GINN model is more likely to outperform the GARCH model when persistence is low ($\pi < 0.9$).

IV. DISCUSSION

Overall, the proposed GINN hybrid model demonstrated robust stock market index prediction performance. It showed superior accuracy in the out-of-sample prediction tasks, surpassing all other tested models in most stock market indexes studied. However, upon further inspection, the performance of the GINN model may not be as dominant as it initially seems. There are many more aspects to consider in the performance of these models.

Firstly, the performance of the GINN and GINN-0 model is qualitatively similar to the GARCH model, as expected. When the GARCH model struggles with the time series data, the GINN model and the GINN-0 model may also fail to yield accurate prediction results. This is illustrated in results from the Nikkei 225 (NIK) and the Hang Seng Index (HSI) datasets, where the TGARCH model and the GJR-GARCH model yielded low accuracy ($R^2 \leq 0.1$) while still outperforming GINN, GINN-0, and GARCH. In the NIK dataset, the GINN-

шесть моделей по сравнению с истинными значениями на рисунке 5. Значения дисперсии представлены в логарифмическом масштабе. Горизонтальная ось — это дата, а вертикальная ось — значение дисперсии.




Рис. 5. Результаты прогнозирования дневной волатильности с шестью протестированными моделями на вневыборочном тестовом наборе данных по индексу S&P 500 (GSPC)

В целом, визуализированные результаты совпадают с числовыми оценками производительности модели. Результаты прогнозирования вне выборки и с использованием LSTM кажутся довольно случайными и едва уловимыми в плане крупных рыночных движений. Модели GJR-GARCH и TGARCH успешно зафиксировали пики на рынке (например, всплеск волатильности в середине 2020 года), при этом, по-видимому, предсказание их величины было более точным, чем у остальных моделей. Однако результаты с высокой изменчивостью в области низкой волатильности кажутся менее точными по сравнению с моделью GARCH. Результаты GARCH в целом более плавные, при этом сохраняются рыночные тенденции. Результаты моделей GINN и GINN-0 изменяются еще меньше по сравнению с ними, до такой степени, что, по-видимому, теряются более тонкие детали (обсуждается далее в Разделе IV).

Для более легкого сравнения трех моделей с наилучшими результатами, результаты прогнозирования на данных индекса S&P 500 (GSPC) моделей GARCH, GINN и GINN-0 представлены на логарифмической шкале на рисунке 6. Горизонтальная ось — это дата, а вертикальная ось — значение дисперсии.

Судя по графику, результаты трех моделей имеют схожую форму, но различаются по величине. Результаты модели GINN выглядят как более сглаженная версия результатов модели GARCH. Пиковые значения гораздо менее экстремальны, а кривая в целом более плавная в повседневных изменениях. Результаты модели GINN-0 очень похожи на результаты модели GINN. Кривые моделей GINN и GINN-0 практически неразличимы, что соответствует близости показателей производительности между ними. Модель GARCH лучше отражает изменения на рынке по сравнению с моделями GINN и GINN-0, так как ее кривая лучше соответствует истинным данным, более точно отображая расположение и величину пиковой волатильности, особенно в периоды высокой волатильности.




Рис. 6. Результаты прогнозирования ежедневной волатильности с использованием модели GARCH, модели GINN и модели GINN-0 на тестовом наборе вне выборки по данным индекса S&P 500 (GSPC)

По сравнению с истинными значениями все три модели показали плохие результаты. Это соответствует в целом низким показателям коэффициента детерминации (R^2) у всех протестированных моделей, при этом модель GINN показала наилучший результат — около 0,33 на наборе данных GSPC.

Что касается производительности модели на данных, смоделированных по процессу GARCH, мы обнаружили, что относительная производительность моделей GINN и GARCH сильно зависит от устойчивости данных временного ряда, и модель GARCH обеспечивает лучшую точность только примерно в половине протестированных смоделированных временных рядов. Устойчивость модели GARCH (1, 1) — это свойство момента в условной дисперсии, и оно определяется как сумма весов $\pi = \alpha + \beta$ [41]. Было установлено, что при высокой устойчивости ($0.9 < \pi < 1$) модель GARCH, по-видимому, работает сопоставимо с моделью GINN или даже превосходит ее, тогда как модель GINN с большей вероятностью превосходит модель GARCH при низкой устойчивости ($\pi < 0.9$).

IV. ОБСУЖДЕНИЕ

В целом, предложенная гибридная модель GINN продемонстрировала устойчивую производительность при прогнозировании фондового рынка. Она показала превосходную точность в задачах прогнозирования на новых данных, превосходя все остальные протестированные модели по большинству изученных фондовых индексов. Однако при дальнейшем внимательном рассмотрении производительности модели GINN может быть не такой dominating, как кажется на первый взгляд. Существуют многие другие аспекты, которые следует учитывать при оценке производительности этих моделей. Во-первых, производительность моделей GINN и GINN-0 качественно схожа с моделью GARCH, как и ожидалось. Когда модель GARCH испытывает трудности с данными временных рядов, модели GINN и GINN-0 также могут не дать точных результатов в прогнозировании. Это иллюстрируется результатами по наборам данных Nikkei 225 (NIK) и Hang Seng Index (HSI), где модели TGARCH и GJR-GARCH показали низкую точность ($R^2 \leq 0.1$), при этом все же превосходя GINN, GINN-0 и GARCH. В наборе данных NIK модель GINN-

0 model ended up in third place, and the GINN and GARCH models placed fourth and fifth, respectively. The GARCH model's low performance led to the low accuracy of the GINN and GINN-0 models, which make direct use of GARCH. This reinforces prior work which demonstrates cases in which GARCH fails to make accurate predictions, and here those cases hinder the performance of the GINN model and the GINN-0 model [10, 17]. Future exploration of GINN-like hybrid models should consider the use of other variants of the ARCH or GARCH-type models.

As for the comparison between the GINN model and the GINN-0 model, the GINN model usually outperforms the GINN-0 model by a small but noticeable margin. Both models always yield better performance than the GARCH model. The GINN model's better performance could result from the fact that it learns market knowledge from both the ground truth volatility and the GARCH model. We are surprised that the GINN-0 model yields better performance than the GARCH model in some cases, even though it doesn't utilize ground truth volatility in the loss function. It is still unclear why a model trained to predict the prediction results from the GARCH model would outperform the GARCH model itself. The smoother curve and profile of the GINN-0 model compared to the GARCH model may suggest that the LSTM component of the GINN-0 model serves as additional regularization for the model, and result in a more consistent prediction. More work is needed to investigate the actual cause of GINN-0's performance gain over the GARCH model.

Thirdly, it is noteworthy that the performance metrics used in the study may not be sufficient to picture the performance thoroughly. As mentioned previously, the prediction results from the GINN model are overly smooth compared to that from the GARCH model. It has fewer peaks and less extreme values, and lost some characteristics of the market. That somehow resulted in a better performance. It seems that the performance metrics used, the R^2 , MSE, and MAE, tend to reward smoother prediction results. One explanation is that the less smooth models, e.g., GJR-GARCH and TGARCH, get it wrong with their variations. They over-predict and under-predict instead of taking the medium and smoothed path. Also, compared to more conservative and average-inclining values, the metrics used punish wrong and extreme prediction values more severely. Thus, when the predicted fluctuating volatility got offset by a few days from the ground truth, it could result in much lower scores even though the market trend it captures is correct. This helps explain why the seemingly more fluctuating GJR-GARCH and TGARCH models generally yield worse scores. In Figure 6, the GARCH model seems to capture the market trend better than the GINN model, with more pronounced peaks and dips, but it ended up with lower scores. This raises the concern of whether the current performance metrics are sufficient or even suitable for stock volatility prediction performance evaluation, and promotes the critical need for a further and more comprehensive study of the performance metrics in the future.

The simulated GARCH process data results unveil more

insights into the performance gain of the GINN model over the GARCH model. The GARCH model and the GINN model yield comparable performance in a time series that perfectly satisfy the GARCH process. This suggests that the superior performance of the GINN model in real-world stock market data could be a result of the GINN model capturing information in the market that doesn't satisfy the GARCH process and the GARCH model fails to catch.

The residuals between the prediction results and the ground truth variance for the GARCH and GINN models are analyzed through their amplitude spectrum with the Fast Fourier transform (FFT) process, as shown in Figure 7. It is found that the residual of the GINN model has a higher amplitude of very low (long-term) frequencies while having a lower amplitude in the high-frequency ranges compared to that from the GARCH model. This shows that the GINN model is better at capturing daily or short-time volatility features with higher frequencies, while picking up less stagnated long-term features that could be inherently noisy and unpredictable.




Fig. 7. Amplitude Spectrum of the Residual of the GARCH and GINN models on the S&P 500 Index (GSPC) data

Another thing that could affect the performance of the GINN model is the value of the weight λ . The current weight is selected because they result in the best average performance on a dedicated dataset to ensure the model's generalizability. However, our testing found that some weight values could result in better accuracy in certain time series data. This leaves room for further optimization if only focusing on modeling a specific time series data.

Lastly, all tested models did poorly in terms of prediction accuracy. One possible reason for that is the differences in the markets in the in-sample and out-of-sample time periods. The markets change over time, including the participants,

Модель 0 заняла третье место, а модели GINN и GARCH заняли четвертое и пятое места соответственно. Низкая производительность модели GARCH привела к низкой точности моделей GINN и GINN-0, которые используют GARCH напрямую. Это подтверждает предыдущие работы, показывающие случаи, в которых GARCH не способен делать точные прогнозы, и здесь эти случаи ухудшают производительность моделей GINN и GINN-0 [10, 17]. Будущие исследования гибридных моделей, подобных GINN, должны рассмотреть возможность использования других вариантов моделей типа ARCH или GARCH.

Что касается сравнения модели GINN и модели GINN-0, модель GINN обычно превосходит модель GINN-0 с небольшой, но заметной разницей. Обе модели всегда демонстрируют лучшую производительность по сравнению с моделью GARCH. Лучшие результаты модели GINN могут быть обусловлены тем, что она изучает рыночные данные как из фактической волатильности, так и из модели GARCH. Нас удивляет, что модель GINN-0 в некоторых случаях показывает лучшую производительность, чем модель GARCH, хотя она не использует фактическую волатильность в функции потерь. До сих пор непонятно, почему модель, обученная прогнозировать результаты предсказаний модели GARCH, может превосходить саму модель GARCH. Более гладкая кривая и профиль модели GINN-0 по сравнению с моделью GARCH могут указывать на то, что компонент LSTM в модели GINN-0 выполняет функцию дополнительной регуляризации для модели и обеспечивает более последовательное предсказание. Необходимо провести больше исследований для выяснения фактической причины прироста производительности GINN-0.

В-третьих, стоит отметить, что метрики производительности, использованные в исследовании, могут быть недостаточными для полного отображения эффективности. Как было упомянуто ранее, результаты прогнозирования модели GINN слишком сглажены по сравнению с результатами модели GARCH. У них меньше пиков и менее экстремальные значения, и некоторые характеристики рынка теряются. Это в какой-то мере приводит к лучшей производительности. Кажется, что использованные метрики производительности, R^2 , MSE и MAE, склонны вознаграждать более сглаженные результаты прогнозирования. Одним из объяснений является то, что менее сглаженные модели, например, GJR-GARCH и TGARCH, ошибаются в своих вариациях. Они переоценивают и недооценивают вместо того, чтобы идти по среднему и сглаженному пути. Кроме того, по сравнению с более консервативными и склонными к усреднению значениями, используемые метрики более строго наказывают за неверные и экстремальные значения прогнозов. Таким образом, когда предсказанная колеблющаяся волатильность смещается на несколько дней относительно фактических данных, это может привести к значительно более низким оценкам, даже несмотря на рыночные

взгляд на прирост производительности модели GINN по сравнению с моделью GARCH. Модель GARCH и модель GINN дают сопоставимые результаты на временном ряде, который полностью удовлетворяет процессу GARCH. Это говорит о том, что превосходная производительность модели GINN на реальных данных фондового рынка может быть результатом того, что модель GINN улавливает информацию на рынке, которая не удовлетворяет процессу GARCH, и которую модель GARCH не может уловить.

Остатки между результатами прогнозирования и истинной дисперсией для моделей GARCH и GINN анализируются через их амплитудный спектр с использованием быстрого преобразования Фурье (FFT), как показано на Рисунке 7. Было обнаружено, что остатки модели GINN имеют более высокую амплитуду очень низких (долгосрочных) частот, при этом амплитуда в диапазонах высоких частот ниже по сравнению с моделью GARCH. Это показывает, что модель GINN лучше улавливает особенности волатильности на ежедневной или краткосрочной основе с более высокими частотами, в то время как она меньше фиксирует застойные долгосрочные особенности, которые по своей природе могут быть шумными и непредсказуемыми.




Рис. 7. Амплитудный спектр остатка моделей GARCH и GINN на данных индекса S&P 500 (GSPC)

Еще один фактор, который может повлиять на производительность модели GINN, это значение веса λ . Текущий вес выбран потому, что он обеспечивает наилучшую среднюю производительность на специализированном наборе данных, чтобы гарантировать обобщаемость модели. Однако наши тесты показали, что некоторые значения веса могут давать лучшую точность для определенных временных рядов. Это оставляет пространство для дальнейшей оптимизации, если сосредоточиться исключительно на моделировании конкретных временных рядов.

Наконец, все протестированные модели показали плохие результаты с точки зрения точности прогнозирования. Одной из возможных причин этого являются различия на рынках в периодах внутри выборки и вне выборки. Рынки меняются со временем, включая участников,

Результаты данных смоделированного процесса GARCH и GINN

regulations, and strategies in use. This may lead to the model learning relationships that are valid for older times but not for the new ages. Many unpredictable factors also contribute to market volatility, such as macroeconomic news, investor sentiment shifts, geopolitical events, and elements of market microstructure. Models based only on historical price changes may approximate volatility trends but have trouble forecasting precise volatility spikes or drops, which are often driven by these external factors. There are a multitude of sources that affect volatility in different ways, and the time series may not be autoregressive after all. The GINN model is a meaningful step toward accurate stock market modeling and prediction, but there is still much work to do before a model can accurately forecast future market trends, if that is at all possible.

Overall, the new hybrid GINN model and the GINN-0 model showed promising performance in stock market time series prediction. They represent a new way of constructing a hybrid model. The GINN model combines the advantages of classic statistical models and modern machine learning models, learning from both the factual ground truth and the market knowledge acquired by the GARCH model. This allows the GINN model to have a better grasp of both general market trends and finer details, resulting in a highly accurate and generalizable model. The GARCH component of the GINN model also serves as an additional regularization in the loss function, working as a guard against overfitting, and improving the generalizability.

V. CONCLUSION

This paper introduced a novel hybrid model for volatility prediction in financial markets, named GARCH-Informed Neural Network (GINN). The GINN model utilized both market ground truth and volatility prediction results from the well-known GARCH model in its model training. This helps the GINN model to capture both general market trends and finer details, and results in better out-of-sample prediction accuracy in stock market volatility prediction tasks. The GINN model is noticeably better than all tested competing time series volatility models. The novel hybrid model structure introduced here provides new avenues for the construction of models for general time series modeling and forecasting.

ACKNOWLEDGMENT

This material is based upon work supported by the Defense Advanced Research Projects Agency through cooperative agreement No. HR00112220029. Any opinions, findings, and conclusions or recommendations expressed in this paper are those of the authors and do not necessarily reflect the views of the sponsors.

The authors are grateful to Nikolas Martelaro for his feedback and comments on this work.

REFERENCES

- [1] B. M. Henrique, V. A. Sobreiro, and H. Kimura, "Literature review: Machine learning techniques applied to financial market prediction," *Expert Systems with Applications*, vol. 124, pp. 226–251, Jun. 2019.
- [2] Y. S. Abu-Mostafa and A. F. Atiya, "Introduction to financial forecasting," *Applied Intelligence*, vol. 6, no. 3, pp. 205–213, Jul. 1996.
- [3] H. Y. Kim and C. H. Won, "Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models," *Expert Systems with Applications*, vol. 103, pp. 25–37, Aug. 2018.
- [4] H. Markowitz, "Portfolio Selection," *The Journal of Finance*, vol. 7, no. 1, pp. 77–91, 1952.
- [5] E. Koo and G. Kim, "A Hybrid Prediction Model Integrating GARCH Models With a Distribution Manipulation Strategy Based on LSTM Networks for Stock Market Volatility," *IEEE Access*, vol. 10, pp. 34 743–34 754, 2022, conference Name: IEEE Access.
- [6] R. F. Engle, "Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation," *Econometrica*, vol. 50, no. 4, pp. 987–1007, 1982, publisher: [Wiley, Econometric Society].
- [7] M. Z. Alam, M. N. Siddiquee, and M. Masukujjaman, "Forecasting Volatility of Stock Indices with ARCH Model," *International Journal of Financial Research*, vol. 4, no. 2, p. 126, Apr. 2013, number: 2.
- [8] T. Bollerslev, "Generalized autoregressive conditional heteroskedasticity," *Journal of Econometrics*, vol. 31, no. 3, pp. 307–327, Apr. 1986.
- [9] P. R. Hansen and A. Lunde, "A forecast comparison of volatility models: does anything beat a GARCH(1,1)?" *Journal of Applied Econometrics*, vol. 20, no. 7, pp. 873–889, 2005.
- [10] P. H. Franses and D. Van Dijk, "Forecasting stock market volatility using (non-linear) Garch models," *Journal of Forecasting*, vol. 15, no. 3, pp. 229–235, Apr. 1996.
- [11] D. B. Nelson, "Conditional Heteroskedasticity in Asset Returns: A New Approach," *Econometrica*, vol. 59, no. 2, pp. 347–370, 1991.
- [12] L. R. Glosten, R. Jagannathan, and D. E. Runkle, "On the Relation between the Expected Value and the Volatility of the Nominal Excess Return on Stocks," *The Journal of Finance*, vol. 48, no. 5, pp. 1779–1801, 1993.
- [13] J.-M. Zakoian, "Threshold heteroskedastic models," *Journal of Economic Dynamics and Control*, vol. 18, no. 5, pp. 931–955, Sep. 1994.
- [14] C. Klüppelberg, A. Lindner, and R. Maller, "A Continuous-Time GARCH Process Driven by a Lévy Process: Stationarity and Second-Order Behaviour," *Journal of Applied Probability*, vol. 41, no. 3, pp. 601–622, 2004, publisher: Applied Probability Trust.
- [15] D. Li, X. Zhang, K. Zhu, and S. Ling, "The ZD-GARCH model: A new way to study heteroscedasticity," *Journal of Econometrics*, vol. 202, no. 1, pp. 1–17, 2018, publisher: Elsevier.
- [16] W. Liu and B. Morley, "Volatility Forecasting in the Hang Seng Index using the GARCH Approach," *Asia-Pacific Financial Markets*, vol. 16, no. 1, pp. 51–63, Mar. 2009.

правила и стратегии, которые используются. Это может привести к тому, что модель будет изучать закономерности, действительно для прежних времен, но не для новых эпох. Многие непредсказуемые факторы также способствуют волатильности рынка, такие как макроэкономические новости, изменения настроений инвесторов, геополитические события и элементы микроструктуры рынка. Модели, основанные только на исторических изменениях цен, могут приблизительно отображать тенденции и волатильности, но испытывают трудности с прогнозированием точных всплесков или спадов волатильности, которые часто вызваны этими внешними факторами. Существует множество источников, которые по-разному влияют на волатильность, и временной ряд может в конечном итоге не быть авторегрессионным. Модель GINN является значимым шагом к точному моделированию и прогнозированию фондового рынка, но всё ещё предстоит проделать большую работу, прежде чем модель сможет точно предсказывать будущие рыночные тенденции. В целом, новая гибридная модель GINN и модель GINN-0 показали перспективные результаты в прогнозировании временных рядов фондового рынка. Они представляют собой новый способ построения гибридной модели. Модель GINN сочетает преимущества классических статистических моделей и современных моделей машинного обучения, обучаясь как на фактических данных, так и на рыночных знаниях, полученных с помощью модели GARCH. Это позволяет модели GINN лучше понимать как общие рыночные тенденции, так и более тонкие детали, что приводит к высокой точности и способности к обобщению. Компонент GARCH в модели GINN также служит дополнительной регуляризацией в функции потерь, действуя как защита от переобучения и улучшая способность к обобщению.

V. ЗАКЛЮЧЕНИЕ

В этой статье представлен новый гибридный подход для прогнозирования волатильности на финансовых рынках, названный нейронной сетью с учетом GARCH (GINN). Модель GINN использовала как реальные рыночные данные, так и результаты прогнозирования волатильности известной модели GARCH при обучении своей модели. Это помогает модели GINN учитывать как общие рыночные тенденции, так и более тонкие детали, что приводит к лучшей точности прогнозов вне выборки при задачах прогнозирования волатильности фондового рынка. Модель GINN заметно превосходит все протестированные конкурирующие модели волатильности временных рядов. Новая структура гибридной модели, представленная здесь, открывает новые возможности для построения моделей для общего моделирования и прогнозирования временных рядов.

ПОДТВЕРЖДЕНИЕ

Этот материал основан на работе, поддержанной Агентством передовых оборонных исследовательских проектов (DARPA) через кооперативное соглашение № HR00112220029. Любые мнения, результаты и выводы или рекомендации, выраженные в этой статье, принадлежат авторам и не обязательно отражают мнения спонсоров.

Авторы благодарны Николасу Мартеларо за его отзыв и комментарии к этой работе.

ЛИТЕРАТУРА

[1] Б. М. Энрике, В. А. Собрейро и Х. Кимура, «Обзор литературы: методы машинного обучения, применяемые к

прогнозирование финансового рынка," *Expert Systems with Applications*, том 124, стр. 226–251, июнь 2019 г. [2] Y. S. Abu-Mostafa и A. F. Atiya, "Введение в финансовое прогнозирование," *Applied Intelligence*, том 6, № 3, стр. 205–213, июль 1996 г. [3] H. Y. Kim и C. H. Won, "Прогнозирование волатильности индекса цен на акции: гибридная модель, интегрирующая LSTM с несколькими моделями типа GARCH," *Expert Systems with Applications*, том 103, стр. 25–37, август 2018 г. [4] H. Markowitz, "Выбор портфеля," *The Journal of Finance*, том 7, № 1, стр. 77–91, 1952 г. [5] E. Koo и G. Kim, "Гибридная модель прогнозирования, интегрирующая модели GARCH с методикой манипулирования распределением на основе сетей LSTM для волатильности фондового рынка," *IEEE Access*, том 10, стр. 34 743–34 754, 2022 г., конференция: IEEE Access. [6] R. F. Engle, "Авторегрессионная условная гетероскедастичность с оценками дисперсии инфляции в Великобритании," *Econometrica*, том 50, № 4, стр. 987–1007, издатель: [Wiley, Econometric Society]. [7] M. Z. Alam, M. N. Siddiquee и M. Masukujja man, "Прогнозирование волатильности

- [17] K. Y. Lee, "Are the GARCH models best in out-of-sample performance?" *Economics Letters*, vol. 37, no. 3, pp. 305–308, Nov. 1991.
- [18] D. McMillan, A. Speight, and O. Apgwilym, "Forecasting UK stock market volatility," *Applied Financial Economics*, vol. 10, no. 4, pp. 435–448, Aug. 2000.
- [19] L. Yu, S. Wang, and K. K. Lai, "A neural-network-based nonlinear metamodeling approach to financial time series forecasting," *Applied Soft Computing*, vol. 9, no. 2, pp. 563–574, Mar. 2009.
- [20] N. K. Ahmed, A. F. Atiya, N. E. Gayar, and H. El-Shishiny, "An Empirical Comparison of Machine Learning Models for Time Series Forecasting," *Econometric Reviews*, vol. 29, no. 5-6, pp. 594–621, Aug. 2010.
- [21] Z. Shen, Y. Zhang, J. Lu, J. Xu, and G. Xiao, "A novel time series forecasting model with deep learning," *Neurocomputing*, vol. 396, pp. 302–313, Jul. 2020.
- [22] N. Kohzadi, M. S. Boyd, B. Kermanshahi, and I. Kaastra, "A comparison of artificial neural network and time series models for forecasting commodity prices," *Neurocomputing*, vol. 10, no. 2, pp. 169–181, Mar. 1996.
- [23] M. Khashei and M. Bijari, "An artificial neural network (p,d,q) model for timeseries forecasting," *Expert Systems with Applications*, vol. 37, no. 1, pp. 479–489, Jan. 2010.
- [24] G. P. Zhang and M. Qi, "Neural network forecasting for seasonal and trend time series," *European Journal of Operational Research*, vol. 160, no. 2, pp. 501–514, Jan. 2005.
- [25] I. Ciuca and J. A. Ware, "Layered neural networks as universal approximators," in *Computational Intelligence Theory and Applications*, ser. Lecture Notes in Computer Science, B. Reusch, Ed. Berlin, Heidelberg: Springer, 1997, pp. 411–415.
- [26] A. M. Schäfer and H. G. Zimmermann, "Recurrent Neural Networks Are Universal Approximators," in *Artificial Neural Networks – ICANN 2006*, ser. Lecture Notes in Computer Science, S. D. Kollias, A. Stafylopatis, W. Duch, and E. Oja, Eds. Berlin, Heidelberg: Springer, 2006, pp. 632–640.
- [27] J. C. B. Gamboa, "Deep Learning for Time-Series Analysis," Jan. 2017. [Online]. Available: <https://arxiv.org/abs/1701.01887v1>
- [28] S. Hochreiter and J. Schmidhuber, "Long Short-term Memory," *Neural computation*, vol. 9, pp. 1735–80, Dec. 1997.
- [29] N. Maknickienė and A. Maknickas, "Application of Neural Network for Forecasting of Exchange Rates and Forex Trading," in *The 7th International Scientific Conference "Business and Management 2012". Selected papers*. Vilnius, Lithuania: Vilnius Gediminas Technical University Publishing House Technika, 2012, pp. 122–127.
- [30] K. Chen, Y. Zhou, and F. Dai, "A LSTM-based method for stock returns prediction: A case study of China stock market," in *2015 IEEE International Conference on Big Data (Big Data)*, Oct. 2015, pp. 2823–2824.
- [31] M. Raissi, P. Perdikaris, and G. E. Karniadakis, "Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations," *Journal of Computational Physics*, vol. 378, pp. 686–707, Feb. 2019.
- [32] G. E. Karniadakis, I. G. Kevrekidis, L. Lu, P. Perdikaris, S. Wang, and L. Yang, "Physics-informed machine learning," *Nature Reviews Physics*, vol. 3, no. 6, pp. 422–440, Jun. 2021.
- [33] J. Chen, J. Pierce, G. Williams, T. W. Simpson, N. Meisel, S. Prabha Narra, and C. McComb, "Accelerating Thermal Simulations in Additive Manufacturing by Training Physics-Informed Neural Networks With Randomly Synthesized Data," *Journal of Computing and Information Science in Engineering*, vol. 24, no. 011004, Jul. 2023.
- [34] K. Sheppard, S. Khrapov, G. Lipták, mikedeltalima, R. Capellini, alejandro cermenio, Hugle, esvhd, S. bot, A. Fortin, JPN, M. Judell, R. Russell, W. Li, 645775992, A. Adams, jbrockmendel, L. Migrator, M. Rabba, M. E. Rose, N. Tretyak, T. Rochette, U. N. O. Leo, X. RENE-CORAIL, X. Du, Joren, and B. Çelik, "bashtage/arch: Release 6.1.0," May 2023. [Online]. Available: <https://zenodo.org/record/7975104>
- [35] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Köpf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai, and S. Chintala, "PyTorch: an imperative style, high-performance deep learning library," in *Proceedings of the 33rd International Conference on Neural Information Processing Systems*. Red Hook, NY, USA: Curran Associates Inc., Dec. 2019, no. 721, pp. 8026–8037.
- [36] S. Ioffe and C. Szegedy, "Batch normalization: accelerating deep network training by reducing internal covariate shift," in *Proceedings of the 32nd International Conference on International Conference on Machine Learning - Volume 37*, ser. ICML'15. Lille, France: JMLR.org, Jul. 2015, pp. 448–456.
- [37] A. F. Agarap, "Deep Learning using Rectified Linear Units (ReLU)," Mar. 2018.
- [38] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A Simple Way to Prevent Neural Networks from Overfitting," *Journal of Machine Learning Research*, vol. 15, no. 56, pp. 1929–1958, 2014.
- [39] I. Loshchilov and F. Hutter, "Decoupled Weight Decay Regularization," Nov. 2017.
- [40] Yahoo, "Yahoo Finance - Stock Market Live, Quotes, Business & Finance News," 2023. [Online]. Available: <https://finance.yahoo.com/>
- [41] C. G. Lamoureux and W. D. Lastrapes, "Persistence in Variance, Structural Change, and the GARCH Model," *Journal of Business & Economic Statistics*, vol. 8, no. 2, pp. 225–234, 1990, publisher: [American Statistical Association, Taylor & Francis, Ltd.].

[17] К. Ю. Ли, «Являются ли модели GARCH лучшим и по показателям вне выборки?» *Economics Letters*, том 37, № 3, стр. 305–308, ноябрь 1991 г. [18] Д. Макмиллан, А. Спайт и О. Апгвилем, «Прогнозирование волатильности фондового рынка Великобритании», *Applied Financial Economics*, том 10, № 4, стр. 435–448, август 2000 г. [19] Л. Ю. С. Ванг и К. К. Лай, «Метод нелинейного метамоделирования на основе нейронной сети для прогнозирования финансовых временных рядов», *Applied Soft Computing*, том 9, № 2, стр. 563–574, март 2009 г. [20] Н. К. Ахмед, А. Ф. Атия, Н. Э. Гайар и Х. Эль-Шишини, «Эмпирическое сравнение моделей машинного обучения для прогнозирования временных рядов», *Econometric Reviews*, том 29, № 5-6, стр. 594–621, август 2010 г. [21] З. Шен, И. Чжан, Дж. Лу, Дж. Сюй и Г. Сяо, «Новая модель прогнозирования временных рядов с использованием глубокого обучения», *Neurocomputing*, том 396, стр. 302–313, июль 2020 г. [22] Н. Кохзади, М. С. Бойд, Б. Керманшахи и И. Кастра, «Сравнение моделей искусственных нейронных сетей и моделей временных рядов для прогнозирования цен на сырьевые товары», *Neurocomputing*, том 10, № 2, стр. 169–181, 1 марта

[31] М. Раисси, П. Пердикарис и Г. Э. Карниадакис, «Нейронные сети с учетом физики: рамки глубокого обучения для решения прямых и обратных задач, включающих нелинейные уравнения с частными производными», *Journal of Computational Physics*, т. 378, с. 686–707, фев. 2019. [32] Г. Э. Карниадакис, И. Г. Кеврекидис, Л. Лу, П. Пердикарис, С. Ванг и Л. Ян, «Машинное обучение с учетом физики», *Nature Reviews Physics*, т. 3, № 6, с. 422–440, июн. 2021. [33] Дж. Чен, Дж. Пирс, Г. Уильямс, Т. В. Симпсон, Н. Мейзел, С. Прабха Нарра и С. Маккомб, «Ускорение тепловых симуляций в аддитивном производстве путем обучения нейронных сетей с учетом физики на случайно синтезированных данных», *Journal of Computing and Information Science in Engineering*, т. 24, № 011004, июл. 2023. [34] К. Шеппард, С. Храпов, Г. Липтяк, mikedeltali, Р. Капеллини, Алехандро Сермено, Hugle, esvhd, C. bot, А. Фортин, JPN, М. Джуделл, Р. Расселл, В. Ли, 645775992, А. Адамс, jbrockmendel, Л. Мигратор, М. Рабба, М. Э. Роуз, Н. Третьяк, Т. Рошетт, У. Н. О. Лео, X. RENE-CORAIL, X.